

BÁO CÁO TIẾN ĐỘ NGHIÊN CỨU

Action Recognition nhẹ và thời gian thực
trên thiết bị biên từ chuỗi frame RGB 2D

Khảo sát phương pháp và phân tích Temporal Shift Module

Sinh viên thực hiện: Nguyễn Hữu Hoàng Anh
Đồng Đăng Tình

Hướng nghiên cứu: Lightweight Video Understanding, Edge AI, TSM-CNN

RGB-only

No depth data

Online inference

Edge deployment

Hà Nội, tháng 06 năm 2026

1. Bài toán nghiên cứu và yêu cầu triển khai

Bài toán

Nhận một luồng video RGB và dự đoán hành động dựa trên **thứ tự, chuyển động và biến đổi theo thời gian** của nhiều frame liên tiếp.

Phạm vi

- ▶ Dữ liệu vào: chuỗi ảnh RGB 2D từ camera.
- ▶ Không dùng ảnh depth, point cloud hay skeleton 3D.
- ▶ Mục tiêu gần: nhận diện hành động/cử chỉ trong video stream.
- ▶ Đầu ra: nhãn hành động và độ tin cậy theo thời gian.

Ràng buộc triển khai edge

- ▶ **Lightweight**: ít FLOPs, ít tham số, bộ nhớ nhỏ.
- ▶ **Realtime**: xử lý liên tục, batch size 1, độ trễ thấp.
- ▶ **Online**: không phụ thuộc frame tương lai khi cần phản hồi ngay.
- ▶ **Ổn định**: hạn chế nhấp nháy nhãn giữa các cửa sổ thời gian.
- ▶ **Dễ triển khai**: backbone 2D được tối ưu tốt trên GPU/TensorRT.


Accuracy

Latency

FPS

Memory

2. Pipeline tổng quát của hệ thống



Hai bài toán thời gian

- ▶ **Offline:** toàn bộ clip đã có sẵn; có thể sử dụng cả frame trước và sau.
- ▶ **Online:** tại thời điểm t chỉ được dùng dữ liệu $\leq t$; phù hợp robot và camera realtime.

Điểm cốt lõi

2D CNN xử lý tốt từng frame nhưng không tự biểu diễn thứ tự thời gian; cần một cơ chế temporal modeling đủ nhẹ cho edge.

Các quyết định ảnh hưởng hiệu năng

- ▶ Độ dài cửa sổ T , stride và chiến lược lấy mẫu frame.
- ▶ Kích thước ảnh, backbone và cách mô hình hóa thời gian.
- ▶ Cơ chế smoothing/trigger sau classifier.

3. Phân loại các hướng tiếp cận

2D CNN + sampling

TSN, temporal pooling

Xử lý từng frame độc lập rồi tổng hợp.

Nhẹ nhất; temporal reasoning hạn chế.

Relation / late fusion

TRN, feature aggregation

Học quan hệ giữa feature của nhiều frame.

Chi phí vừa; fusion diễn ra muộn.

Sequence model

CNN-LSTM, GRU, TCN, attention

Mô hình hóa chuỗi feature sau backbone.

Linh hoạt; latency/bộ nhớ phụ thuộc module.

Temporal module

TSM, TEA, TDN, ACTION-Net

Chèn mô-đun thời gian vào CNN 2D.

Cân bằng accuracy và efficiency.

Efficient 3D CNN

X3D, MoViNet

Convolution trên không gian và thời gian.

Motion mạnh; triển khai phức tạp hơn 2D.

Dynamic inference

Frame selection, early exit

Chỉ xử lý frame/nhánh cần thiết.

Hiệu quả phụ thuộc chính sách chọn.

Video Transformer

Temporal attention, token mixing

Quan hệ dài hạn và linh hoạt.

Thường nặng với edge nhỏ.

Two-stream


RGB + optical flow

Tách appearance và motion.

Optical flow làm tăng compute và latency.

Lưu ý thuật ngữ: “3D CNN” ở đây là tích chập theo hai chiều không gian và một chiều thời gian (H, W, T); không có nghĩa là sử dụng camera depth.

4. Nhóm 1 - 2D CNN và temporal sampling: TSN



Bản chất

Chia video thành nhiều segment, lấy một snippet đại diện trong mỗi segment, xử lý bằng CNN 2D và tổng hợp dự đoán ở cuối.

Ưu điểm

- ▶ Bao phủ video dài với ít frame.
- ▶ Dùng trực tiếp pretrained 2D CNN.
- ▶ Là baseline đơn giản và dễ triển khai.


Hạn chế

- ▶ Feature từng frame được trích độc lập.
- ▶ Average/consensus không mô hình hóa tốt thứ tự.
- ▶ Khó phân biệt hành động đảo chiều như mở/đóng.

Vai trò trong đề tài

Cung cấp baseline và chiến lược sampling; TSM có thể xây trên cùng backbone/sampling nhưng thêm trao đổi temporal ở nhiều tầng.

5. Nhóm 2 - Temporal Relation Network và late fusion



Bản chất

Trích feature từng frame bằng 2D CNN, sau đó học các quan hệ giữa cặp/nhóm frame ở nhiều thang thời gian.

So với TSN

- ▶ Có thể suy luận quan hệ và thứ tự giữa frame.
- ▶ Diễn giải được quan hệ ngắn và dài hạn.
- ▶ Vẫn tận dụng backbone ảnh 2D.

Điểm yếu cho edge

- ▶ Temporal fusion chủ yếu ở feature cấp cao.
- ▶ Số tổ hợp frame tăng theo số quan hệ được xét.
- ▶ Không trao đổi motion ở các tầng thấp như TSM.

Kết luận: phù hợp làm baseline quan hệ thời gian, nhưng không phải lựa chọn nhẹ nhất cho online stream.

Tài liệu: Zhou et al., Temporal Relational Reasoning in Videos, ECCV 2018.

6. Nhóm 3 - CNN kết hợp RNN, TCN hoặc Attention

Temporal head	Cách hoạt động	Điểm mạnh	Vấn đề khi deploy
CNN–LSTM/GRU	Feature từng frame được đưa tuần tự qua trạng thái ẩn.	Tự nhiên với chuỗi; giữ ngữ cảnh quá khứ.	Tính toán tuần tự; khó song song; state cần reset đúng.
Temporal ConvNet	Conv1D theo trục thời gian trên chuỗi feature.	Song song tốt; receptive field điều khiển được.	Thêm temporal layers; cần buffer cố định.
Temporal Attention	Attention giữa các frame/token.	Quan hệ dài hạn; chọn frame quan trọng.	Chi phí tăng theo số frame/token; bộ nhớ lớn hơn.

Bài toán phù hợp :

- ▶ Chuỗi dài hoặc trạng thái kéo dài cần bộ nhớ thời gian rõ ràng.
- ▶ Muốn tách spatial encoder khỏi temporal classifier.

So với TSM

Sequence head tổng hợp feature sau/giữa backbone; TSM dịch channel ngay trong các block CNN nên fusion xuất hiện ở nhiều mức biểu diễn với cấu trúc đơn giản hơn.

7. Nhóm 4 - Efficient temporal modules trong CNN 2D

Phương pháp	Cơ chế temporal	Ưu điểm	Nhận xét triển khai
TSM (2019)	Shift một phần channel sang frame lân cận.	Không thêm tham số và FLOPs lý thuyết; online/offline.	Đơn giản, dễ gắn vào backbone 2D; phù hợp baseline triển khai.
TEA (2020)	Motion Excitation + Multiple Temporal Aggregation.	Học motion ngắn hạn và aggregation dài hơn.	Accuracy tốt hơn nhưng block phức tạp hơn TSM.
TDN (2021)	Temporal difference ở mức local và segment.	Khai thác chênh lệch frame rõ ràng, đa thang thời gian.	Hiệu quả nhưng thêm nhánh xử lý difference và fusion.
ACTION-Net (2021)	Excitation theo không gian, channel và motion.	Nhiều đường kích hoạt đặc trưng temporal.	Vẫn dựa CNN 2D nhưng chi phí lớn hơn shift thuần túy.

Xu hướng chung: giữ backbone 2D để tận dụng thư viện/hardware tối ưu, sau đó bổ sung một primitive temporal rẻ hơn 3D convolution. Trong nhóm này, TSM là điểm bắt đầu phù hợp nhất để kiểm chứng pipeline edge.

8. Nhóm 5 - Efficient 3D video networks

X3D - CVPR 2020

- ▶ Bắt đầu từ một kiến trúc rất nhỏ và mở rộng dần theo các trục: temporal duration, spatial resolution, width và depth.
- ▶ Tạo họ model có accuracy/FLOPs tốt hơn nhiều 3D CNN truyền thống.
- ▶ Phù hợp làm đối chứng khi cần motion modeling mạnh.



MoViNet - CVPR 2021

- ▶ Họ mobile video network được tìm kiếm theo ràng buộc compute/memory.
- ▶ Hỗ trợ **streaming inference** bằng causal convolution và stream buffer.
- ▶ Là phương án 3D CNN đáng chú ý cho thiết bị di động.



Đánh giá

X3D/MoViNet vẫn chỉ sử dụng RGB 2D theo thời gian, nhưng kernel 3D và pipeline deployment phức tạp hơn TSM + 2D CNN. MoViNet là đối chứng online quan trọng; TSM thuận lợi hơn để bắt đầu trên codebase CNN hiện có.

9. Mức độ phù hợp của TSM-CNN cho bài toán hiện tại

Ưu điểm

- ▶ Chuyển một 2D CNN thành mô hình có trao đổi thông tin thời gian.
- ▶ **Không thêm tham số và FLOPs lý thuyết** cho phép shift.
- ▶ Có cả phiên bản offline và online.
- ▶ Tận dụng pretrained ImageNet và các kernel 2D đã tối ưu.
- ▶ Có thể gắn vào ResNet, MobileNet và các backbone CNN khác.

Nhược điểm

- ▶ Shift gây **data movement**; latency thực tế có thể tăng.
- ▶ Dịch quá nhiều channel làm giảm spatial modeling.
- ▶ Cần đặt shift đúng vị trí và chọn tỉ lệ hợp lý.

Ý nghĩa cho lab: TSM cho phép xây dựng một baseline temporal rõ ràng mà không phải thay toàn bộ pipeline sang 3D CNN hoặc Transformer.

Simple primitive

Low latency

Online capable

2D hardware friendly

Tài liệu: Lin, Gan and Han, TSM: Temporal Shift Module for Efficient Video Understanding, ICCV 2019.

10. Nguyên lý toán học: temporal shift thay cho 3D conv

Nếu dùng tích chập 1D theo thời gian

Với feature tại thời điểm i , một kernel thời gian kích thước 3 có dạng:

$$Y_i = w_{-1}X_{i-1} + w_0X_i + w_{+1}X_{i+1}$$

- ▶ X_{i-1}, X_i, X_{i+1} : feature của ba frame lân cận.
- ▶ w_{-1}, w_0, w_{+1} : trọng số học được theo trục thời gian.
- ▶ Cách này cần phép nhân-cộng theo chiều thời gian, gần với 3D convolution.

Vấn đề với edge

3D convolution biểu diễn motion tốt nhưng làm tăng compute, bộ nhớ activation và độ phức tạp triển khai so với CNN 2D.

Tài liệu: Mục 3.1, bài báo TSM, trang 3.

Cách nhìn của TSM

Tách convolution theo thời gian thành hai ý tưởng:


$$X_i^{-1} = X_{i-1}, \quad X_i^0 = X_i, \quad X_i^{+1} = X_{i+1}$$

$$Y_i = w_{-1}X_i^{-1} + w_0X_i^0 + w_{+1}X_i^{+1}$$

- ▶ Bước shift chỉ hoán chuyển feature theo trục T .
- ▶ Phần nhân-cộng được “gộp” vào lớp 2D convolution phía sau.
- ▶ Vì vậy TSM thêm temporal context mà không thêm tham số hay FLOPs lý thuyết.

Diễn giải ngắn: thay vì học kernel 3D mới, TSM trao một phần channel giữa các frame để CNN 2D nhìn thấy feature quá khứ/hiện tại/tương lai.

11. Cơ chế dịch channel trong một block TSM



Hình minh họa: các ô là nhóm channel trong feature map, không phải pixel ảnh. TSM thao tác trên activation tensor sau một số lớp CNN.

Offline TSM

Với residual TSM mặc định trong paper:

- ▶ 1/8 channel dịch từ $t - 1$ sang t .
- ▶ 1/8 channel dịch từ $t + 1$ sang t .
- ▶ 3/4 channel còn lại giữ nguyên frame hiện tại.


Lý do chỉ shift 1 phần feature

Shift quá nhiều channel làm tăng data movement và làm mất thông tin không gian của frame hiện tại. Partial shift giữ cân bằng giữa motion cue và spatial feature.

Sau khi shift, lớp 2D convolution tiếp theo xử lý feature đã trộn thời gian. Backbone vẫn là 2D CNN, nhưng representation đã có thông tin temporal.

Tài liệu: Mục 3.3, bài báo TSM, trang 4.

12. Ý tưởng cốt lõi của Temporal Shift Module



(a) The original tensor without shift. (b) Offline temporal shift (bi-direction). (c) Online temporal shift (uni-direction).

Figure 1. **Temporal Shift Module (TSM)** performs efficient temporal modeling by moving the feature map along the temporal dimension. It is computationally free on top of a 2D convolution, but achieves strong temporal modeling ability. TSM efficiently supports both **offline** and **online** video recognition. Bi-directional TSM mingles both past and future frames with the current frame, which is suitable for high-throughput offline video recognition. Uni-directional TSM mingles only the past frame with the current frame, which is suitable for low-latency online video recognition.

Feature video tại một tầng:

$$A \in \mathbb{R}^{N \times C \times T \times H \times W}$$

- ▶ N : batch size; C : số channel.
- ▶ T : số frame; H, W : kích thước feature map.
- ▶ Dịch một phần channel -1 frame, một phần $+1$ frame; phần còn lại giữ nguyên.

Thông tin thời gian sau phép Shift

Conv 2D tại thời điểm t nhận feature có nguồn gốc từ $t - 1$, t và $t + 1$. Nhiều residual block nối tiếp sẽ mở rộng temporal receptive field.

Note

TSM dịch **feature channel** bên trong mạng, không dịch trực tiếp pixel RGB.

13. Offline TSM và Online TSM

Bi-directional TSM - offline

- ▶ Cấu hình mặc định: 1/8 channel từ quá khứ và 1/8 từ tương lai.
- ▶ Context đầy đủ hơn, nhưng phải có frame tương lai nên không phản hồi tức thời.



Phù hợp xử lý clip/video đã có sẵn, nơi accuracy quan trọng hơn độ trễ phản hồi.

Uni-directional TSM - online

- ▶ Chỉ truyền feature từ quá khứ sang frame hiện tại.
- ▶ Cache 1/8 feature map tại mỗi residual block; paper báo cáo khoảng 0.9 MB với ResNet-50.
- ▶ Có thể dự đoán theo từng frame với overhead nhỏ.






Figure 4. Uni-directional TSM for online video recognition.

14. Thiết kế kỹ thuật: partial shift và residual shift



(a) Overhead vs. proportion.




(b) Residual vs. in-place.

Naive shift không tối ưu


- ▶ Shift nhiều channel làm tăng data movement; paper đo overhead khoảng 12–14% trong trường hợp cực đoan.
- ▶ Mất channel của frame hiện tại làm giảm khả năng học spatial feature.

Hai sửa đổi chính

1. **Partial shift**: offline mặc định dịch 1/4 tổng số channel (1/8 mỗi hướng).
2. **Residual shift**: đặt TSM trong residual branch để identity path vẫn giữ feature gốc.



(a) In-place TSM.



(b) Residual TSM.

15. Kết quả chính của bài báo TSM

Cải thiện so với TSN cùng ResNet-50, 8 frame

Dataset	TSN Top-1	TSM Top-1	Δ
Kinetics	70.6	74.1	+3.5
UCF101	91.7	95.9	+4.2
HMDB51	64.7	73.5	+8.8
Something-V1	20.5	47.3	+28.0
Something-V2	30.4	61.7	+31.3
Jester	83.9	97.0	+11.7

Mức tăng lớn nhất xuất hiện trên dataset phụ thuộc mạnh vào thứ tự và chuyển động, cho thấy temporal modeling là phần đóng góp chính.

Tài liệu: Bảng 1 và Bảng 8, bài báo TSM, trang 5 và 8.

Online và edge deployment trong paper

Thiết bị	Latency	Power
Jetson Nano CPU	47.8 ms	4.8 W
Jetson Nano GPU	13.4 ms	4.5 W
Jetson TX2 CPU	36.4 ms	5.6 W
Jetson TX2 GPU	8.5 ms	5.8 W
Raspberry Pi 4B	69.6 ms	3.8 W
Galaxy Note8	34.5 ms	—

Điều kiện so sánh

- Kết quả được thực nghiệm với online với model TSM + MobileNetV2 , được biên dịch bằng TVM theo như tác giả mô tả.
- Kết quả có thể không tái hiện được với thiết bị như jetson orin tại Lab

16. Hạn chế và vấn đề khi áp dụng tại lab

Hạn chế của phương pháp

- ▶ Shift chủ yếu trao đổi thông tin cục bộ giữa frame lân cận; quan hệ rất dài hạn cần nhiều block hoặc cơ chế bổ sung.
- ▶ “Zero FLOPs” không đồng nghĩa zero latency do data movement.
- ▶ Kết quả paper dùng dataset lớn và pretraining mạnh; dataset nhỏ dễ overfit.
- ▶ TSM nhận dạng clip, không tự giải quyết temporal localization hoặc xác định lúc hành động bắt đầu/kết thúc.

Các vấn đề triển khai thực tế

- ▶ Đồng bộ clip theo thời lượng thật, số frame và FPS giữa train/inference.
- ▶ Crop người/upper-body phải ổn định; nhiều crop làm temporal feature sai lệch.
- ▶ Cần lớp nền/non-action, split theo người và phiên quay để tránh leakage.
- ▶ Online prediction cần EMA, hysteresis, consecutive trigger và cooldown.
- ▶ Phải đo end-to-end: capture + crop + preprocess + inference + postprocess.

Research gap ở mức triển khai

Paper chứng minh TSM hiệu quả trên benchmark chuẩn, nhưng chưa trả lời cấu hình nào tối ưu cho camera xa, dữ liệu lab nhỏ, crop người không ổn định và ngân sách tài nguyên chia sẻ với ROS 2/perception trên Jetson Orin Nano.