

Báo cáo nghiên cứu khoa học

HỌC VIỆN CÔNG NGHỆ BƯU CHÍNH VIỄN THÔNG

Khoa Kỹ thuật Điện tử 1

VIDEO MAMBA STATE SPACE MODEL HIỆU QUẢ CHO HIỂU VIDEO DÀI

Phân tích bài báo *VideoMamba: State Space Model for Efficient Video Understanding*

Hướng nghiên cứu: Action Recognition trên thiết bị biên

Tác giả bài báo: Kunchang Li và cộng sự

Năm công bố: 2024

Hà Nội, tháng 08 năm 2026

Nội dung trình bày

- | | | |
|---|-----------------------------|--|
| 1 | Bài toán và mục tiêu | Video dài tạo redundancy cục bộ, dependency toàn cục và chi phí attention lớn. |
| 2 | Kiến trúc | Token hóa video 3D, B-Mamba và spatiotemporal scan. |
| 3 | Recipe huấn luyện | Architecture scaling, self-distillation và masked video pretraining. |
| 4 | Thực nghiệm | Kết quả ngắn hạn, dài hạn và hiệu năng. |

Trọng tâm: cách VideoMamba tổ chức chuỗi token 3D và huấn luyện hiệu quả cho video dài.

1.1. Video dài cần mô hình hóa vừa cục bộ vừa toàn cục

Hai tính chất đối nghịch

- ▶ **Redundancy cục bộ:** nhiều patch lân cận gần như trùng nhau.
- ▶ **Dependency toàn cục:** hành động có thể phụ thuộc vào các frame rất xa.
- ▶ **Mục tiêu:** đồng thời nhận biết motion tinh vi và ngữ cảnh dài.

Chi phí theo độ dài chuỗi L

Self-Attention : $O(L^2 D)$

Selective SSM : $O(LD)$

Khi tăng frame hoặc resolution, L tăng nhanh; quadratic attention trở thành nút thắt memory.

Khoảng trống của các họ mô hình

Họ	Điểm mạnh	Hạn chế chính
3D CNN	Receptive field cục bộ	Khó giữ dependency dài.
Transformer	Context toàn cục	Attention đắt với video dài.
VideoMamba	Scan tuyến tính	Cần thiết kế thứ tự scan phù hợp.

Mục tiêu nghiên cứu

Điều chỉnh Mamba cho video nhằm mô hình hóa dependency không-thời gian dài với chi phí tuyến tính theo số token.

2.1. Input video được chuyển thành chuỗi token không-thời gian

1. Video tensor $\mathbf{X}_v$

$$\mathbf{X}_v \in \mathbb{R}^{3 \times T \times H \times W}$$

$\mathbf{X}_v$: video clip input, đã lấy mẫu frame và resize/crop.

3: ba kênh màu RGB.

T : số frame theo trục thời gian.

H, W : chiều cao, chiều rộng của mỗi frame.

2. Patchify và L

Kernel = stride: $(1 \times 16 \times 16)$.

Mỗi patch nằm trong một frame, nên $t = T$.

Lưới patch mỗi frame:

$$h = H/16, \quad w = W/16$$

$$L = T \times \frac{H}{16} \times \frac{W}{16}$$

L : số patch token.

3. Chuỗi đưa vào encoder

$$\mathbf{X} = [\mathbf{X}_{cls}, \mathbf{X}_p] \\ + \mathbf{p}_s + \mathbf{p}_t$$


$\mathbf{X}_p$: L patch embedding, mỗi token C chiều.

[CLS]: token học được; đại diện toàn video, đi vào classification head.

$\mathbf{p}_s$: vị trí patch trong frame.

$\mathbf{p}_t$: thời điểm/frame của patch.

2.2. VideoMamba: encoder ViT-like với B-Mamba cho chuỗi token 3D



Luồng dữ liệu VideoMamba

- 1 3D convolution ($1 \times 16 \times 16$) tạo các patch không-thời gian không chồng lấp.
- 2 Ghép [CLS] với patch sequence; cộng spatial và temporal position embedding.
- 3 Xếp chồng L B-Mamba block; biểu diễn [CLS] đi qua linear head.


Video tạo chuỗi token dài

$$\mathbf{X}_v \in \mathbb{R}^{3 \times T \times H \times W}$$

$$L = \frac{T}{1} \cdot \frac{H}{16} \cdot \frac{W}{16}$$

Ví dụ $16 \times 224 \times 224 \Rightarrow 16 \times 14 \times 14 = 3136$ token.

2.3. Spatiotemporal bidirectional scan strategies




Điểm khác nhau

Spatial-first, temporal-first, spatiotemporal v1 và v2 đều chạy forward + backward; khác biệt duy nhất là thứ tự token trước khi đi vào SSM.


Kết quả ablation

Trên SSV2, spatial-first đạt 65.1%, cao nhất trong các scan strategy được đánh giá; tác giả chọn thiết kế này vì đơn giản.

3.1. Masked video pretraining: objective và masking strategy




(a) input video




(b) random masking



(c) tube masking



(d) clip-row masking



(e) frame-row masking



(f) attention masking

Objective

VideoMamba được pretrain trên video; output của token không bị mask được align với feature từ CLIP-ViT teacher. Masking strategy là một thành phần của recipe này.

Masking và ablation trên SSV2

Conv1D ưu tiên token liên tục. Random: 67.4

Tube: 66.3

Clip-row: 68.2 Frame-row: 67.8 **Attention: 68.5**


3.2. Architecture scaling và self-distillation

Model scale

Model	D	Dim	P
Tiny	24	192	7M
Small	24	384	26M
Middle	32	576	74M
Base	24	768	98M

Quan sát khi scale

VideoMamba-B huấn luyện từ đầu có xu hướng overfit và không tốt hơn VideoMamba-S; early stopping không thay thế được regularization.



Teacher → student, chỉ khi train

VideoMamba-S đã học tốt làm teacher cho VideoMamba-M; căn chỉnh final feature map bằng L2 loss. Inference vẫn là một VideoMamba duy nhất.

4.1. Thiết lập thực nghiệm

Scale up trên ảnh

ImageNet-1K

Kiểm tra khả năng scale model/input trước khi transfer sang video; benchmark có 1.28M ảnh train, 1,000 lớp.

Video ngắn

Kinetics-400

Phân loại hành động theo scene; video trung bình 10 giây.

Something-Something V2

Nhảy với diễn biến thời gian; video trung bình 4 giây.

Video dài

Breakfast và COIN

Nhận biết hoạt động và thủ tục dài; Breakfast gồm 77 giờ video, COIN có 180 procedural tasks.

LVU

Long-form Video Understanding: clip phim 1–3 phút, 9 tác vụ content, metadata và user engagement.

Thiết lập chính

Fine-tune video từ ImageNet-1K; masked alignment dùng CLIP-ViT teacher cho pretraining self-supervised.

4.2. Kết quả video ngắn: Kinetics-400 và Something-Something V2

Kinetics-400, supervised

Model	Top-1	Top-5
TimeSformer-L	80.7	94.7
ViViT-L	81.3	95.4
VideoMamba-M_{f64}	83.3	96.1

Ablation: scan strategy

Spatial-first đạt 65.1% trên SSV2, cao nhất trong các scan strategy được đánh giá; Alternative SF&TF đạt cùng mức nhưng phức tạp hơn.

Something-Something V2, supervised

Model	Top-1	Top-5
TimeSformer-L	62.5	–
ViViT-L	65.4	89.8
VideoMamba-M	68.4	91.6

Ablation: token budget

K400 tăng theo số frame; SSV2 có optimum khác vì video ngắn. Nhiều token hơn không luôn cải thiện kết quả.

4.3. Kết quả video dài: Breakfast, COIN và LVU

Kết quả long-term video understanding

Benchmark	Cấu hình	Metric	Kết quả
Breakfast	VideoMamba _{f32}	Top-1	97.9
COIN	VideoMamba _{f64}	Top-1	90.4
LVU	VideoMamba _{f32}	Scene	70.37
LVU	VideoMamba _{f32}	Director	67.29
LVU	VideoMamba _{f32}	Genre	65.24


Điểm khác biệt

- ▶ Train end-to-end trên video dài.
- ▶ Không phụ thuộc pipeline trích feature trước rồi mới suy luận.
- ▶ Dễ tăng frame nhờ scan có chi phí tuyến tính.

Thông điệp

Với long context, cách token mixer ảnh hưởng trực tiếp cả memory lẫn khả năng học quan hệ xa.

4.4. Computational efficiency trên video dài



Throughput

32 frame: xấp xỉ **2×** nhanh hơn TimeSformer-Ti.

64 frame: xấp xỉ **6×** nhanh hơn.

GPU memory

32 frame: dùng khoảng **20×** ít memory hơn.

64 frame: dùng khoảng **40×** ít memory hơn.

5. Conclusion, limitations và research relevance

Kết luận của bài báo

- ▶ **Scale:** self-distillation giúp model lớn hội tụ tốt hơn.
- ▶ **Motion:** spatial-first scan và masking giữ nhậy với hành động ngắn.
- ▶ **Long video:** train end-to-end hiệu quả hơn các pipeline feature-based.
- ▶ **Multimodal:** có thể kết hợp text encoder và cross-modal decoder.

Relevance to our research

Diễn giải cho Action Recognition Edge: linear scan có thể hỗ trợ tăng số frame trong memory giới hạn. Latency thực tế cần benchmark trên đúng Jetson/NPU và pipeline decode.

Giới hạn được tác giả nêu

- ▶ Chưa kiểm chứng toàn diện ở kích thước cực lớn.
- ▶ Chưa tích hợp audio hoặc mô hình ngôn ngữ lớn cho video theo giờ.
- ▶ Chưa đánh giá trực tiếp khi chuyển từ benchmark GPU sang thiết bị edge.

Phạm vi kết luận

Các kết quả hiệu năng và accuracy được báo cáo theo cấu hình training, input và GPU của paper; không suy diễn trực tiếp sang một edge platform cụ thể.