HỌC VIỆN CÔNG NGHỆ BƯU CHÍNH VIỄN THÔNG
Khoa Kĩ thuật Điện tử 1

BÁO CÁO TIẾN ĐỘ NGHIÊN CỨU

VideoMamba-Tiny trên CTPGesture v1

Isolated Gesture Classification, Continuous Recognition
và đối chiếu các công trình liên quan

Sinh viên: Nguyễn Hữu Hoàng Anh

Lĩnh vực: Video Action / Gesture Recognition

Đầu vào: RGB video, CTPGesture v1 (9 lớp)

Hà Nội, ngày 15 tháng 10 năm 2026

Nội dung báo cáo

STT	Nhóm nội dung	Trọng tâm
1	**Thiết lập**	Dataset, checkpoint, đánh giá isolated / continuous.
2	**Thực nghiệm**	Accuracy, Macro-F1, confusion matrices, post-processing.
3	**Hiệu năng**	Parameters, estimated GFLOPs, latency, throughput.
4	**Bốn bài đối chứng**	Venue, phương pháp, bằng chứng Table/Page, khác protocol.
5	**Hướng tiếp theo**	Fair causal benchmark và phân đoạn chuỗi hành động.

Phân biệt kết quả nhận dạng đoạn đã biết ranh giới và kết quả nhận dạng trên toàn bộ video.

1. Dataset CTPGesture v1 và kiểm kê test set

Dữ liệu đầu vào

- Video RGB, nhãn **theo từng frame**.
- **9 lớp**: 8 lệnh giao thông và No Gesture.
- Frame rate: **15 FPS**.
- Test audit trong notebook: **11 video**.
- Tổng cộng **67.356 frames**.

Đơn vị đánh giá

1.728
Temporal segments

869 / 859
No Gesture / Gesture

Test video IDs:
002, 004, 008, 010, 012, 014, 016, 018, 101, 102, 104

Nguồn: Notebook Cell 10: OFFICIAL CTPGesture TEST SPLIT.

1. Pipeline VideoMamba-Tiny và hai giao thức



A. Isolated classification

- Ground-truth boundaries tạo clip.
- Lấy 16 frame đều trong mỗi segment.
- 1 dự đoán / segment.
- Báo cáo Accuracy và Macro-F1.

B. Continuous recognition

- Window **32 frames**, step **8 frames**.
- Overlap **75%**; sample 16 frames.
- Tổng hợp xác suất các cửa sổ lên frame.
- Không phải phép dự đoán causal thuần.

Nguồn: Notebook Cells 13–18, 22.

1. Cấu hình thử nghiệm được lưu trong notebook

Thành phần	Thiết lập	Ghi chú
Model	VideoMamba-Tiny	24 layers
Weights	`checkpoint-best.pth`	Epoch 17
Input tensor	$[B, 3, 16, 224, 224]$	FP32
Số lớp	9	No Gesture + 8 gestures
Window / step	32 / 8 frames	2,13 s / 0,53 s @15 FPS
Sample offsets	$0, 2, 4, \ldots, 30$	16 frames mỗi window
Inference GPU	NVIDIA Tesla T4	`native_cuda`
Evaluation batch	4	Isolated và continuous
Runtime benchmark batch	1	Đo model-only latency

Nguồn: Notebook Cells 6, 8, 10, 26. Training hyperparameters cần bổ sung từ notebook huấn luyện.

2. Isolated Classification – kết quả 9 lớp

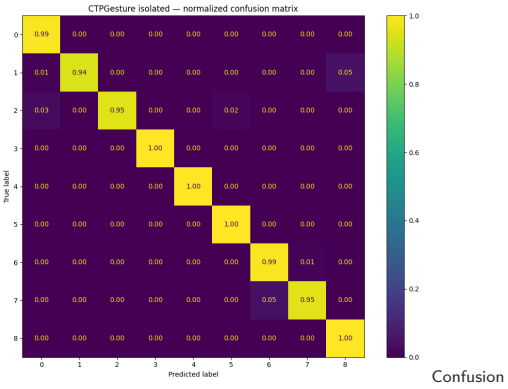
98,55%
Top-1 Accuracy
1.728 segments

97,96%
Macro-F1
9 classes

Gesture-only (GT lớp 1–8)

- **859** gesture segments.
- Accuracy: **98,02%**.
- Macro-F1: **98,24%**.
- Balanced Accuracy (9 lớp): 98,12%.

Diễn giải: Phân loại chính xác cao khi *đã biết trước* ranh giới cử chỉ.



Confusion matrix – isolated

Nguồn: Notebook Cell 16, ảnh `cell17_output5.png`.

2. Continuous Recognition – RAW, toàn bộ test video

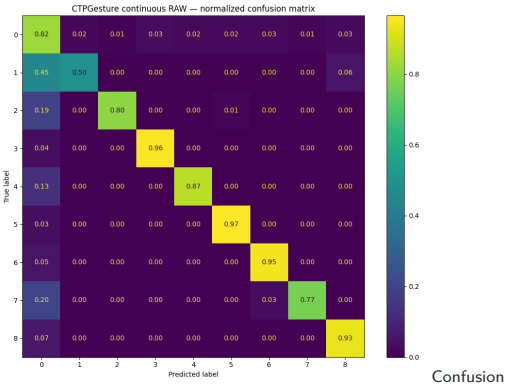
83,98%
Global Frame Accuracy

80,61%
Global Macro-F1

Thiết lập và temporal metrics

- 11 videos / **67.356 frames**.
- **8.392** windows (32/8).
- Mean Gesture Recall: **94,80%**.
- Mean Temporal Overlap: **65,32%**.

Vấn đề: Hiệu năng giảm ở bài toán liên tục, cần kiểm tra transitions và temporal boundaries.



Confusion matrix – continuous RAW

Nguồn: Notebook Cell 22, ảnh `cell23_output5.png`.

2. Hậu xử lí – hiệu quả và giới hạn suy luận

Cấu hình	Frame Acc.	Macro-F1	Temporal overlap
RAW, không hậu xử lí	83,98%	80,61%	65,32%
R3, loại đoạn ngắn dưới 1 s	**83,99%**	**80,63%**	**65,90%**
S1, smoothing	83,81%	79,71%	64,85%

Quan sát

- R3 tăng overlap 0,58 điểm %.
- Frame Accuracy tăng rất nhỏ.
- Probability smoothing làm giảm Macro-F1.

Nguồn: Notebook Cell 24: post-processing ablation.

Giới hạn methodology

R3 được chọn khi thử các cấu hình trên **test set**. Do vậy R3 chỉ có ý nghĩa thăm dò; báo cáo **RAW** là kết quả chính cho đến khi tune trên validation.

3. Model Complexity và Runtime (NVIDIA Tesla T4)

6,96M	29,03	50,65	19,74
Parameters	Estimated GFLOPs/clip	ms/clip, batch 1	clips/s, batch 1

Phép đo	Kết quả	Điều kiện
Mean / median / p95 latency	50,65 / 50,79 / 51,00 ms	Batch=1, FP32
Continuous model forward	48,17 ms/window	Batch=4
Full-test wall time	968,01 s / 8.392 windows	11 videos
Effective throughput	8,67 windows/s	Full evaluation loop
Extra GPU allocation	56,58 MiB	Không phải peak VRAM tổng

Nguồn: Notebook Cells 22, 26. 29,03 GFLOPs là **ước lượng custom counter**, cần kiểm tra quy ước MAC/FLOP.

3. Giải thích số đo latency và khả năng real-time

Những gì đã đo

- **50,65 ms**: chạy 1 clip / model forward, FP32, Tesla T4.
- **8,67 windows/s**: throughput của phép đánh giá offline, có decode.
- 1 window gồm 32 frames (2,13 s ở 15 FPS).
- Bước dịch window: 8 frames (0,53 s).

Những gì chưa đo

- End-to-end latency trên luồng camera.
- Tốc độ và bộ nhớ trên Jetson/thiết bị biên.
- Delay xuất lệnh causal theo frame.
- Tổng peak GPU memory và mean±std qua nhiều seeds.

Không được suy ra 19,74 clips/s là 19,74 camera FPS. Cách gán xác suất từ cửa sổ chồng lấn có thể dùng frame tương lai với một số frame đích.

4. Bốn công trình đối chứng: nơi công bố

ID	Bài báo	Venue / Năm	Ranking / trạng thái
P1	Xiong et al. – MD-GCN	Electronics, 2021	JCR 2025 Q2 (Engineering, EEE)
P2	Xiao et al. – NTPGR	Scientific Reports, 2025	JCR 2025 Q1 (Multidisciplinary)
P3	Zhang et al. – BiLSTM–Transformer	Electronics, 2026	JCR 2025 Q2 (Engineering, EEE)
P4	Li et al. – RSC-GestureNet	arXiv preprint, 2026	Không gán quartile/CORE

Quartile áp dụng cho **tạp chí** trong một **ngành và năm cụ thể**, không phản ánh mức trích dẫn của bài báo. Thông tin PRCV Oral của P4 do tác giả tự ghi, chưa đối chiếu proceedings.

Nguồn: Bốn PDF trong thư mục 261015; Electronics Journal Statistics (MDPI), số JCR 2025.

4. Phương pháp đối chứng: Xiong (2021) và Xiao (2025)

P1 – MD-GCN (2021)

Input / Model: Gesture Skeleton Extractor rồi Multichannel Dilated Graph CNN, học quan hệ khớp theo không gian và thời gian.

Published: MD-GCN **98,95%**; các baseline RGB P3D **92,21%**, C3D **87,12%**.

Vị trí: Section 6.1 (11 video train, 9 video test); **Table 3, trang 12** (Accuracy).

Lưu ý: C3D/P3D là kết quả P1 đánh giá lại, không phải kết quả dataset trong bài C3D/P3D gốc.

P2 – NTPGR (2025)

Input / Model: EPFFNet lấy skeleton; MSNet kết hợp CNN, LSTM và temporal/channel attention.

Published: 97,56% Accuracy; 759/778 cử chỉ nhận dạng đúng; response time 0,76 s.

Vị trí: Table 2, trang 11; Tables 3–4, trang 13–14.

Lưu ý: 10 test videos / 778 gesture instances; không đồng nhất split 11 videos của notebook.

Nguồn: P1: electronics-10-00551-v2.pdf; P2: s41598-025-02833-y.pdf.

4. Phương pháp đối chứng: Zhang (2026) và Li (2026)

P3 – BiLSTM–Transformer (2026)

Input / Model: YOLOv11m-Pose (17 keypoints), chuỗi **40 frames**, BiLSTM kết hợp Transformer.

Published: 98,91% Accuracy, F1=98,91%.

Vị trí: Table 1 (test 10 videos); **Tables 2–4, trang 16–19**.

Cảnh báo: Table 3 ghi BiLSTM 96,48%, đoạn diễn giải không nhất quán; thời gian suy luận bỏ qua chi phí pose extractor.

P4 – RSC-GestureNet (2026)

Input / Model: Reliability-aware pose features, graph reasoning, pose–RGB fusion và causal temporal recognition.

Published: 93,33±0,24% Accuracy; **91,71±0,27% Macro-F1**.

Vị trí: Section 4.1, **Table 1 trang 9**: official CTPGesture v1, causal window 32/4, trung bình 3 seeds.

Vai trò: Đối chứng gần nhất cho continuous nhưng hiện vẫn khác cách suy luận.

Nguồn: P3: electronics-15-02578.pdf; P4: 2608.02200v1.pdf.

4. Evidence matrix: số liệu trích từ đâu?

ID	Chỉ số công bố	Bằng chứng	Đơn vị / split
P1	C3D 87,12%; P3D 92,21%; MD-GCN 98,95%	**Table 3, PDF trang 12**	Clip-level, 9 video test
P2	NTPGR **97,56%**	**Table 2, PDF trang 11**	Gesture-instance, 778 samples
P3	BiLSTM–Transformer **98,91%**	**Tables 2–4, trang 16–19**	Pose sequence, 10 video test
P4	RSC **93,33% Acc**; **91,71% Macro-F1**	**Table 1, PDF trang 9**	Causal-frame, official split, 3 seeds

Không gộp các giá trị Accuracy thành một leaderboard duy nhất: clip classification, gesture-instance recognition và frame-level causal evaluation đo các nhiệm vụ khác nhau.

4. Isolated: published results dưới các protocol khác nhau

Model	Modality	Accuracy	Bối cảnh
3D ResNet (P1 re-eval.)	RGB video	81,16%	P1 Table 3, 9 test videos
C3D (P1 re-eval.)	RGB video	87,12%	P1 Table 3, 9 test videos
P3D (P1 re-eval.)	RGB video	92,21%	P1 Table 3, 9 test videos
MD-GCN (P1)	Skeleton	98,95%	P1 Table 3, 9 test videos
NTPGR (P2)	Skeleton + temporal	97,56%	P2 Table 2, 778 gestures
BiLSTM–Transformer (P3)	Skeleton + temporal	98,91%	P3 Table 2, 10 videos
VideoMamba-Tiny (ours)	**RGB video**	**98,55%**	**11 videos, 1.728 segments, 9 classes**

Đây là bảng đối chiếu literature, không phải fair SOTA. Kết quả gesture-only của nhóm: 98,02% trên 859 segments với GT labels 1–8.

4. Continuous: đặt cạnh causal benchmark của P4

Model	Frame Acc.	Macro-F1	Protocol
GRU (P4 reimplementation)	88,82%	87,10%	Causal 32/4
TCN (P4 reimplementation)	89,88%	88,29%	Causal 32/4
MD-GCN (P4 reimplementation)	90,08%	88,48%	Causal 32/4
RSC-GestureNet (P4)	**93,33%**	**91,71%**	Causal 32/4, 3 seeds
VideoMamba-Tiny RAW (ours)	**83,98%**	**80,61%**	Window 32/8, overlap aggregation

Ranh giới so sánh: P4 gán nhãn theo quá khứ (causal). Notebook cộng xác suất từ các cửa sổ phủ lên frame nên có thể sử dụng frame tương lai. P4 báo cáo mean$\pm$std qua ba seed; notebook mới có một checkpoint.

Nguồn: P4 Table 1 (trang 9); notebook Cell 22.

5. Những gì đã chứng minh và các hạn chế

Kết quả đã có

- RGB end-to-end; không cần skeleton extractor.
- Isolated: **98,55%** Accuracy, **97,96%** Macro-F1.
- Continuous RAW: **83,98%** FrameAcc, **80,61%** Macro-F1.
- **6,96M** params, **50,65 ms/clip** trên T4.
- Có nguồn Table/Page cho bốn bài đối chứng.

Chưa đủ bằng chứng

- Cùng tên dataset nhưng khác test split/metric.
- Chưa phải inference causal end-to-end.
- GFLOPs mới là custom estimate.
- Chưa có multi-seed, Edit Score và Segmental F1.
- Chưa tách được đóng góp mới so với VideoMamba-Tiny gốc bằng ablation.

Ý nghĩa: Sự chênh lệch isolated / continuous chỉ ra yêu cầu cải thiện temporal transition, boundary modeling và protocol đánh giá.

5. Kế hoạch thực nghiệm tiếp theo

P	Đầu việc	Kết quả cần bàn giao
P0	Validation split riêng từ train	Không tune R3/post-processing trên official test.
P0	Causal end-aligned VideoMamba	Đánh giá 32/4, không dùng future frames, cùng metric P4.
P1	Temporal segmentation metrics	Edit Score, Segmental F1@10/25/50, per-class F1.
P1	Multi-seed experiments	Mean$\pm$std từ tối thiểu ba seeds.
P1	Đánh giá efficiency chuẩn	Xác thực GFLOPs, peak VRAM, streaming latency.
P2	So sánh cùng RGB modality	Triển khai lại P3D/C3D trên cùng video split.
P2	Ablation cho đề xuất	Chỉ rõ modification mới và đóng góp so với backbone gốc.

Ưu tiên: Causal protocol chung với RSC-GestureNet, sau đó bổ sung thí nghiệm so sánh công bằng.

Kết luận và danh mục tài liệu

Đánh giá bước đầu trên CTPGesture v1

VideoMamba-Tiny đạt **98,55% isolated Accuracy** và **83,98% continuous Frame Accuracy**; các kết quả literature được đối chiếu theo nguồn, không suy diễn thành bảng SOTA chung protocol.

Bốn công trình có PDF trong thư mục báo cáo:

[P1] Xiong et al., *Electronics* (2021), DOI: 10.3390/electronics10050551 – Table 3.

[P2] Xiao et al., *Scientific Reports* (2025), DOI: 10.1038/s41598-025-02833-y – Table 2.

[P3] Zhang et al., *Electronics* (2026), DOI: 10.3390/electronics15122578 – Tables 2–4.

[P4] Li et al., arXiv:2608.02200v1 (2026) – Table 1.

Tài liệu, notebook và nguồn kết quả:
`https://github.com/HoangAnh301194/Research-notes/tree/main/Research_Report/261015`